# Moderní trendy (12)

# Relační databáze

- data model: instance → databáze → tabulka → řádka
- např. Oracle Database, Microsoft SQL Server, MySQL, PostgreSQL,...
- dotazovací jazyky real-world SQL; formální relační algebra)
- dotazovací vzory
  - o selekce dle podmínek, projekce, joiny, agregace, derivace nových hodnot, rekurze,...

# Normální formy

- model funkční závislosti; 1NF, 2NF, 3NF, BCNF
- cíl normalizace DB schémat do NF (pomocí dekompozice či syntézy)
- motivace snížení redundance dat, zabránění anomáliím
- ale... data jsou roztříštěna v malých kouscích, které musí být při dotazování spojeny

#### Transakce

- model transakce = sekvence DB operací READ, WRITE, COMMIT, ABORT
- **cíl** vynucení ACID, efektivní parelalení/konkurentní provedení

# Big data

- nemá standardní definici
- Informace o velkém objemu, rychlosti (generace) a/nebo velké rozmanitosti, které vyžadují nový způsob zpracování, aby umožnily lepší rozhodování, objevování a optimalizaci.
- zdroje big data:
  - o sociální sítě (všichni generujeme data)
  - o vědecké nástroje (sbírání všech druhů dat)
  - o **mobilní zařízení** (neustálé sledování všeho)
  - o sensory a sítě (měření všeho možného)
- základní čtyři V:
  - Volume (objem)
    - objem dat roste exponencionálně
    - i velké množství malých dat může vést k Big Data
  - Variety (rozmanitost)
    - různé formáty, typy, struktury
    - od semi-strukturovaných XML až k nestrukturovaným multimédiím)
  - Velicoty (rychlost)
    - data se generují rychle a potřebují být rychle zpracována
  - Veracity (věrohodnost)
    - nekonzistence, neúplnost, prodleva, dvojsmysly, odhady,...

# NoSQL databáze

- vše je dnes v cloudu
  - SaaS (Software as a Service)
  - o PaaS (Platform as a Service)
  - o **laaS** (Infrastructure as a Service)
- formát dat se stává neznámým či nekonzistentním
- exponencionální nárust množství dat
- aktualizace dat již není tak častá
- očekává se, že data budou nahrazena
- silná konzistence již není hlavním cílem
- je třeba nový přístup, relační DB již nenásledují moderní trendy
  - o distribuované filesystémy
  - MapReduce apod.
  - o cloud computing
  - NoSQL databáze
  - skladiště dat
  - o large scaled machine learning
- NoSQL opět nemá přesnou definici
  - Next-generation databáze adresující většinou následující: být nerelační, distribuovaný, open-source a horizontálně škálovatelný.
- často bez schémat, snadno replikovatelné, jednoduché API, eventuálně konzistentní,...
- základní typy:
  - o key-value
  - o wide-column
  - document stores
  - o graph databases
- ... a pak objektové databáze, nativní XML databáze, RDF úložiště,...

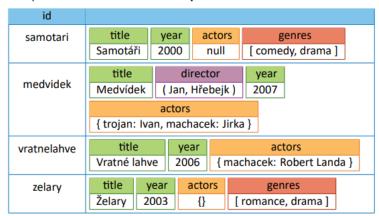
#### Key-value

- nejjednodušší typ NoSQL DB
- funguje jako jednoduchá hash tabulka (mapování)
- páry klíčů a hodnot
  - o **klíč** = id, identifikátor, primární klíč
  - o hodnota = binární objekt, black box pro DB systém,...
- CRUD dotazy pro určitý klíč
- jednoduchý model skvělý výkon, lehce škálovatelný, ale nevhodný pro komplexní data
- skvělé pro session data, profily uživatelů, nákupní košíky... (přístup k hodnotám jen přes klíče)

- nevhodné, když jsou vztahy mezi entitami, dotaz chce přístup jen k části hodnoty, množina operací,...
- např. Redis, MemcachedDB, HazelCast,...

#### Wide column stores

- column family (tabulka) kolekce podobných řádek (ne nutně identických)
- **řádka** = kolekce sloupců, spojená s unikátním klíčem řádky
- sloupec = jméno a hodnota sloupce, většinou skaláry, listy, mapy, množiny,...
   Sample data: table of movies in Apache Cassandra



- dotazy CRUD řádky v určité column family
  - o výběr řádek dle klíče řádku či jednoduché podmínky
- vhodné pro logování událostí, CMS, blogy,...
  - o tj. strukturovaná flat data s podobným schématem
- nevhodné, jsou-li vyžadované ACID transakce, komplexní dotazy apod.
- např. Apache Cassanra

#### Document stores

- data model **dokumenty** 
  - o hierarchická stromová struktura (JSON, XML,...)
  - o skalární hodnoty, mapy, seznamy, množiny, vnořené dokumenty,...
  - mají unikátní identifikátor
  - jsou organizovány do kolekcí
- dotazy CUD dokumentu, získání řádku dle komplexních podmínek dotazu
- rozšířené key-value DB, kde hodnota je prozkoumatelná

Sample data: collection of movies in MongoDB

```
{
    _id: ObjectId("1"),
    title: "Vratné lahve", year: 2006,
    actors: [ "Zdeněk Svěrák", "Jiří Macháček" ]
}

{
    _id: ObjectId("2"),
    title: "Samotáři", year: 2000,
    actors: [ "Jitka Schneiderová", "Ivan Trojan", "Jiří Macháček" ]
}
```

- vhodné pro logování událostí, CMS, blogy, analýzy webu, e-commerce,...
  - o tj. pro strukturované dokumenty s podobným schématem
- nevhodné pro množinové operace přes vícero dokumentů, pokud by se design dokumentové struktury často měnil,...
- např. MongoDB, Couchbase, CouchDB,....

## Grafové databáze

- property graphs
  - o přímé/nepřímé grafy, tj. kolekce:
    - nodů (vrcholů) pro real-world entity
    - vztahů (hran) mezi nody
  - o nody i vztahy mohou být spojeny s dalšími properties
- transakční velké množství malých grafů
- netransakční malé množství velkých grafů
- dotazy CRUD nodu/vztahu v grafu, grafové algoritmy, průchody, sub/super-grafové dotazy, dotazy založené na podobnosti,....
- vhodné pro sociální sítě, směrování, location-based služby, doporučovací služby, chemické sloučeniny, lingvistick stromy,... (tj. pro grafové struktury)
- nevhodné pro dávkové operace, příliš velké grafy apod.
- např. Neo4j, Titan,...

#### Nativní XML databáze

- XML dokumenty (stromová struktura, vnořené elementy/atributy, textové hodnoty,...)
- dokumenty organizovány do kolekcí
- např. Sedna, Tamino,...
- různé dotazovací jazyky:
  - o XPath (navigace)
  - XQuery (dotazování)
  - XSLT (transformace)

# RDF úložiště

- RDF trojice
  - o komponenty: subjekt, predikát, objekt
  - o každá trojice reprezentuje tvrzení (statement) o real-world entitě
  - o může být nahlíženo jako na grafy (hrany = subjekty/objekty, hrany = tvrzení)
- dotazovací jazyk SPARQL
- např. Apache Jena, rdf4j,...

# Sample data: RDF graph of movies

```
Oprefix i: <http://db.cz/terms#>
Oprefix m: <http://db.cz/movies/> .
@prefix a: <http://db.cz/actors/> .
m:vratnelahve
 rdf:type i:Movie ; i:title "Vratné lahve" ;
 i:year 2006;
 i:actor a:sverak , a:machacek .
m:samotari
 rdf:type i:Movie ; i:title "Samotáři" ;
 i:year 2000 ;
 i:actor a:schneiderova , a:trojan , a:machacek .
m:medvidek
 rdf:type i:Movie ; i:title "Medvidek" ;
 i:year 2007;
 i:actor a:machacek , a:trojan ;
 i:director "Jan Hřebejk" .
```

#### Další vlastnosti NoSQL

- cílem je respektovat přirozenost dat reálného světa
  - o tj. datové struktury a vzájemné vztahy

#### - agregátní stuktura

- agregát = jednotka dat s komplexní strukturou
- o kolekce příbuzných dat, které chceme brát jako jednotku
- o např. hodnota v key-value, dokumenty v DS, řádky či column family ve WCS,...
- o důležitá atomicita databázových operací (jeden agregát v jednu chvíli)
- různé typy systémů:
  - aggregate-ignorant relační, grafy
  - aggregate-oriented key-value, document, wide-column,...

## elastické škálování

- o tradiční přístup scaling-up (větší servery kvůli větší zátěži)
- o nový přístup scaling-out (distribuce dat mezi vícero hostů)

#### distribuce dat

- sharding určitý způsob rozdělení dat do separátních skupin
- o replikace držení vícera kopií dat
- **automatické zpracování** automatické zálohy, distribuce apod.
- uvolněná konzistence eventuální konzistence (BASE vlastnosti)

#### bez schémat

- o uvolněné či chybějící schéma
- přináší větší flexibilitu (neuniformní data, strukturální změny,...)
- ale stejně většinou musíme znát strukturu dat (tj. implicitní schéma)

#### - open-source, jednoduché API

polyglot persistence = užití různých datových úložišť při různých příležitostech